Arquitectura de Visión Artificial para el Cocinado Inteligente

Cómo funciona el proyecto, paso a paso
Proyecto de visión artificial y planificación de cocinado · octubre de 2026

1. Qué problema resuelve

Preparar un alimento en una airfryer suele exigir buscar una receta, identificar el programa adecuado y decidir cuánto tiempo y a qué temperatura cocinar. Esas decisiones cambian según el alimento, el tamaño de las piezas y la cantidad que hay en la cesta. No siempre es fácil encontrar instrucciones adaptadas a la preparación concreta.

El objetivo de este proyecto es **simplificar ese proceso mediante inteligencia artificial**: que la airfryer pueda observar su contenido, reconocer los alimentos, analizar sus características y proponer un programa de cocinado. La aspiración a largo plazo es avanzar hacia un sistema adaptable a muchas familias de alimentos, recetas y modelos de aparato.

La innovación no consiste en seleccionar una receta a partir de una fotografía, sino en **conectar varios análisis de visión artificial con un motor que utiliza esa información para personalizar la propuesta**. Actualmente, el proyecto cuenta con un prototipo funcional de software y una arquitectura modular diseñada para ampliar progresivamente el reconocimiento de alimentos y facilitar su futura integración en electrodomésticos.

2. Por qué es interesante para un fabricante

Cada vez valoramos más las herramientas que nos ahorran pasos en tareas cotidianas. El usuario puede estar ocupado, tener poca experiencia cocinando o, simplemente, no querer buscar instrucciones y ajustar manualmente el aparato. Una airfryer que interprete la cesta podría ofrecer una experiencia más sencilla: **introducir el alimento, revisar una propuesta y comenzar**.

Para el fabricante, el interés está en explorar una función de producto diferenciadora, más flexible que una colección de programas fijos. La reducción real de tiempo de configuración, la comodidad percibida y la aceptación de los usuarios serían aspectos que convendría medir en una prueba piloto; todavía no son beneficios comerciales demostrados.

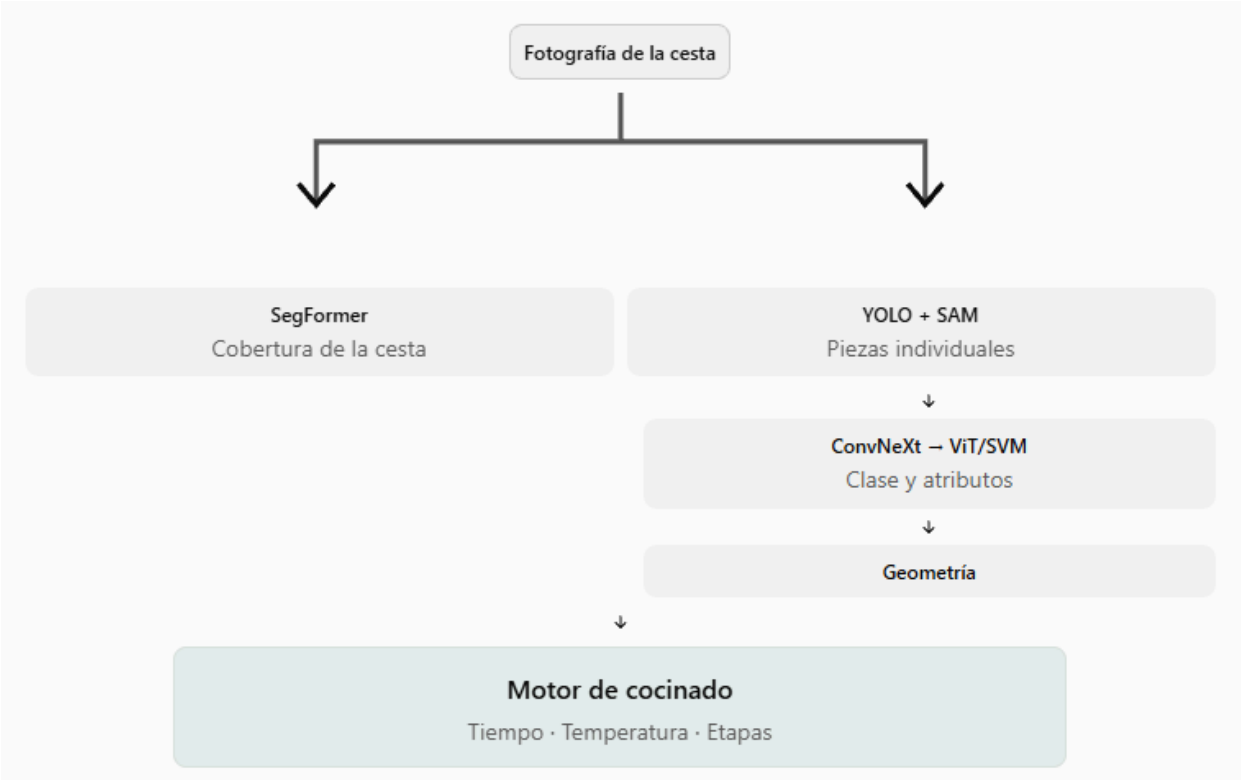
3. Recorrido real del software

El código está organizado en módulos independientes. Al recibir una fotografía, sigue este recorrido:

Imagen → Separar alimento y fondo → Segmentar en piezas individuales → Clasificación del alimento → Atributos especiales por alimento → Geometría → Propuesta de cocinado.

Cada pieza recibe un identificador que permite mantener unidos sus resultados durante todo el proceso. La preparación de datos y la extracción de recetas son herramientas auxiliares: sirven para entrenar y ampliar el sistema, pero no se ejecutan cada vez que se analiza una cesta.

Más allá del entrenamiento de los modelos, desarrollé una arquitectura modular que conecta las distintas etapas mediante un sistema de ejecución coordinado. Cada módulo conserva los resultados e identificadores de las piezas, permitiendo seguir el proceso desde la imagen original hasta la propuesta de cocinado. También incorporé herramientas de preparación de datos, evaluación experimental y pruebas automatizadas para facilitar el desarrollo y la mejora independiente de cada componente.



4. Preparación de los datos

El entrenamiento combina **fotografías reales de alimentos en cestas de airfryer** con **imágenes obtenidas de Internet**. Las primeras ayudan a representar el entorno de uso —fondo de la bandeja, iluminación, distribución y posibles solapamientos—; las segundas aportan variedad de apariencias y preparaciones, haciendo mucho más robusto el modelo.

Ya existe un programa para descargar imágenes mediante consultas. Después se realiza una limpieza: **SHA-256** detecta archivos idénticos y **pHash** señala fotografías visualmente muy parecidas. También se revisan la integridad, la resolución, la calidad y las etiquetas. Por último, las imágenes relacionadas se mantienen en la misma partición para evitar resultados de evaluación artificialmente optimistas.

La biblioteca de ampliación reúne **más de 119.000 imágenes en 172 categorías**, en proceso de validación. Recopilar nuevas imágenes es relativamente sencillo; incorporarlas de forma fiable exige revisar sus etiquetas, ajustar el modelo y comprobar su rendimiento.

5. Segmentar alimento y fondo: SegFormer-B0

La primera etapa de visión utiliza **SegFormer-B0** para distinguir qué píxeles pertenecen a alimentos y cuáles al fondo. Es un modelo de segmentación semántica basado en *transformers*: analiza características de distintas zonas y escalas de la imagen y produce una máscara de dos clases.

¿Para qué sirve? Para estimar la **cobertura superficial** de la cesta. Este modelo permite calcular qué porcentaje de la superficie visible de la cesta está ocupado por alimentos, proporcionando una medida de cobertura útil para adaptar las propuestas de cocinado. Por ejemplo, en unas patatas fritas permite diferenciar visualmente una bandeja poco cubierta de otra casi llena. La cámara y la región útil de la cesta son calibradas para interpretar correctamente ese porcentaje.

Se eligió SegFormer tras compararlo con una alternativa semántica YOLO26n. En 114 fotografías obtuvo **92,82 % de IoU** de alimento frente al **90,63 %** de YOLO y redujo el error medio de cobertura de **1,55 a 1,01 puntos porcentuales**. La IoU mide el solapamiento entre la máscara predicha y la real.

6. Segmentar cada pieza: YOLO11n + SAM 2.1

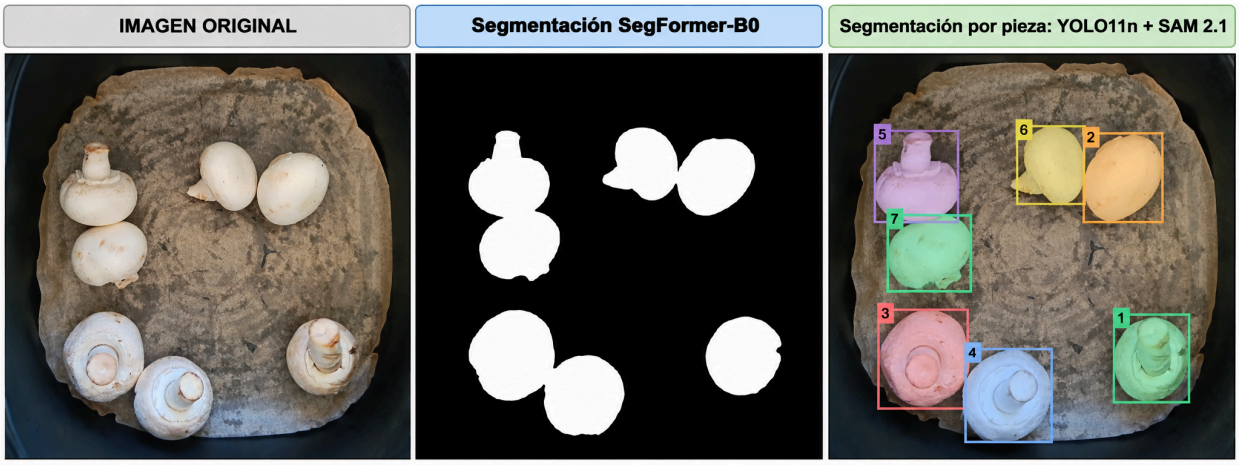
Saber dónde hay comida no basta: también interesa distinguir las piezas. La **segmentación por instancia** produce un contorno y un identificador para cada elemento visible.

Se combina **YOLO11n**, una red rápida que detecta y propone máscaras individuales, con **SAM 2.1 Tiny**, un modelo de segmentación que refina esos contornos. El código convierte

automáticamente cada propuesta de YOLO en una caja y un punto interior para guiar a SAM. El resultado permite analizar por separado las distintas piezas de una misma cesta.

En un test histórico de **115 fotografías y 2.008 piezas anotadas**, la combinación obtuvo **0,928 de IoU de unión de máscaras** y **0,816 de AP de máscaras**. Con este modelo buscamos estimar el tamaño medio del alimento, explicado en el apartado 9.

Resultado Ejecución SegFormer-B0 y YOLO11n + SAM 2.1:



7. Identificar el alimento: DINOv3 ConvNeXt-B

Una vez separadas las piezas, el sistema recorta cada una y ejecuta un clasificador. El modelo seleccionado es **ConvNeXt-B preentrenado con DINOv3 y ajustado al proyecto**.

ConvNeXt es una red convolucional: aprende patrones visuales como bordes, texturas y formas, y los combina para distinguir categorías. El preentrenamiento DINOv3 le proporciona representaciones visuales generales; mediante *fine-tuning* se adapta después a los alimentos concretos.

Se comparó con un **Vision Transformer (ViT) con cabeza lineal** y otro enfoque ViT con **votación de clasificadores**. ConvNeXt alcanzó la mayor exactitud puntual en validación (**92,40 %**, frente al **92,18 %** y el **91,06 %** de esas alternativas). En el test reservado acertó **553 de 603 imágenes: 91,71 %**.

La versión operativa distingue **siete categorías de cortes de pollo**. Cuando su confianza calibrada no alcanza el umbral operativo, deja la categoría pendiente de revisión.

8. Añadir información específica: el detector de rebozado

Reconocer una pechuga no indica si está rebozada, y ese detalle puede influir en la preparación. Para evitar crear una clase distinta para cada combinación —«pechuga»,

«pechuga rebozada», «filete rebozado», etc.—, la arquitectura incorpora **modelos especialistas** después de la clasificación principal, que aportan mayor información del alimento y mejoran la personalización de la receta.

El primero determina si una pieza está **rebozada o no**. Combina un **DINOv3 ViT-B/16**, que convierte la imagen en un vector de características mediante relaciones entre parches, con un **SVM de kernel RBF**, que aprende a separar ambos grupos utilizando esos vectores. En 1.449 imágenes de test obtuvo **96,20 % de exactitud equilibrada**.

Estado actual: este especialista está evaluado con imágenes de pollo y se ejecuta sobre todas las piezas detectadas; su resultado requiere confirmación antes de modificar el plan. **Evolución prevista:** activar especialistas según la familia —por ejemplo, carnes, pescados o mariscos— e incorporar otros atributos sin multiplicar las clases del modelo principal.

9. Analizar el tamaño y la forma de las piezas

Con las máscaras individuales, **OpenCV y NumPy** calculan áreas y medidas geométricas de cada pieza. Para comparar formas se centran los contornos, se busca una orientación común mediante **PCA** y se normalizan sus tamaños. Así pueden superponerse y obtener una **máscara representativa** de una clase.

El problema principal es la **oclusión**: cuando las piezas se amontonan, la cámara solo ve parte de algunas de ellas. Por eso se estudia una regla que seleccione **las dos mayores máscaras válidas y visibles**, alinee sus siluetas buscando el mejor giro y obtenga una forma media, conservando por separado el tamaño de la pieza mayor. Esta última merece especial atención: las piezas pequeñas no deben ocultar la necesidad de cocinar adecuadamente la más grande.

La herramienta de investigación ya permite seleccionar máscaras por tamaño y mejorar su alineamiento; en un ensayo, la coincidencia de formas pasó de **0,793 a 0,818 de IoU**.

10. El motor de cocinado: convertir la visión en una propuesta

La última fase actúa como el **«cocinero» del sistema**. No es otra red neuronal: es un motor de reglas en Python, con perfiles de recetas en JSON, que recibe la categoría, los atributos, las dimensiones disponibles y la cobertura de cesta.

Parte de un **tiempo y una temperatura de referencia** para el alimento y calcula ajustes según los datos disponibles:

Tiempo propuesto = tiempo base × factor de tamaño × factor de área × factor de estado × factor de rebozado.

El motor ya puede organizar **programas con varias fases de temperatura** y agrupar piezas con preparaciones compatibles. La cobertura de la cesta se utiliza actualmente para

aconsejar una mejor distribución o varias tandas. **El ajuste automático del tiempo según una cesta más o menos llena es una mejora propuesta**, que deberá calibrarse mediante cocciones comparables con distintas cargas.

Esta separación permite incorporar alimentos y recetas modificando sus perfiles sin volver a entrenar todos los modelos visuales.

11. Ampliar automáticamente el conocimiento: recetas en vídeo

El proyecto cuenta con una herramienta auxiliar que busca vídeos de recetas en **TikTok e Instagram** mediante consultas, permite seleccionar resultados y descargar los vídeos escogidos. Después utiliza **Whisper** para transcribir el audio y **OCR** para leer textos superpuestos.

A partir de esas evidencias se proponen **alimento, tiempo, temperatura y etapas de cocción**, incluso cuando la receta cambia de temperatura durante el proceso. Una interfaz de revisión permite corregir la información y guardar capturas del alimento antes, durante o después de cocinarlo.

El objetivo es aprovechar esas recetas para enriquecer los perfiles de cocinado y obtener nuevas imágenes útiles para los datasets.

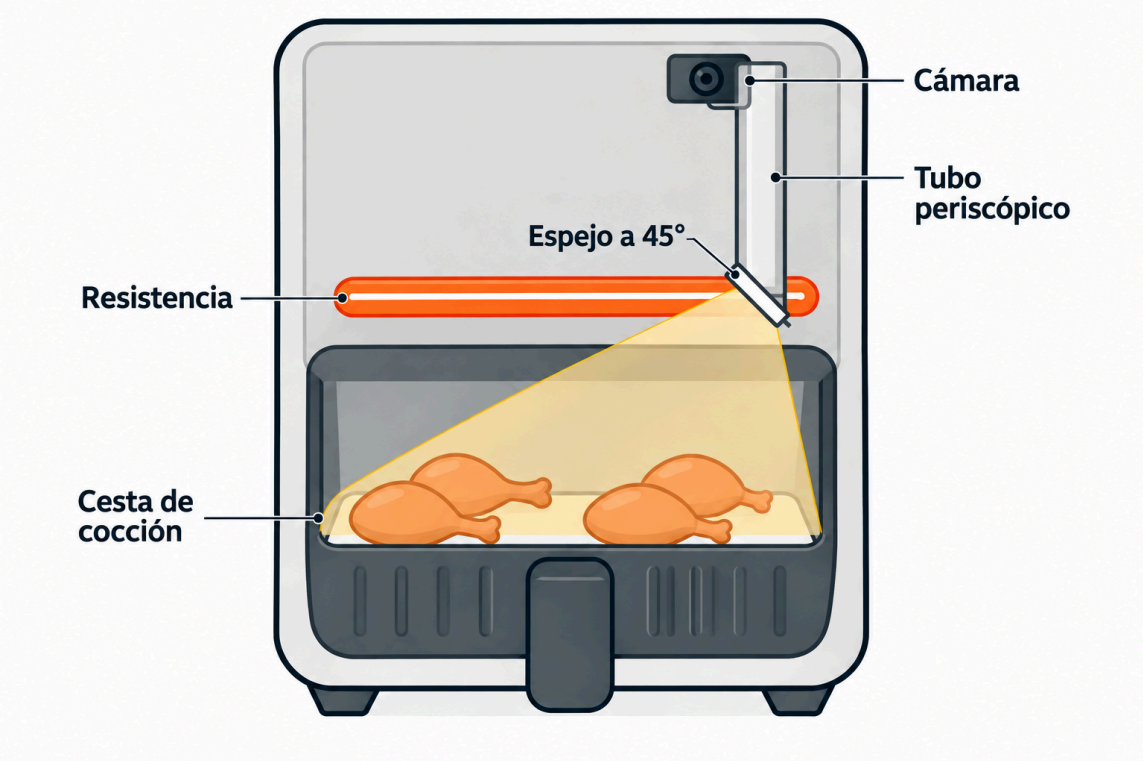
12. Cómo integraría la cámara dentro de una airfryer

Mi propuesta es **mantener la cámara en un compartimento superior protegido**, alejado del aire más caliente y de la grasa, y llevar la imagen de la cesta hasta su objetivo mediante **un espejo plano de primera superficie**. El recorrido óptico permitiría que el sensor no tuviera que colocarse directamente sobre la comida ni quedar expuesto a las mismas condiciones que el interior de cocción.

El sistema se compondría de cuatro elementos:

1. **Cámara y electrónica protegidas:** alojamiento superior térmicamente aislado, con ventilación o refrigeración dimensionada a partir de mediciones reales.
2. **Un espejo de primera superficie:** desvía el recorrido de la luz hasta la cámara, evitando reflejos secundarios propios de los espejos domésticos. Su posición y el objetivo deben diseñarse para ver toda la zona útil de la cesta.
3. **Ventana óptica sellada y accesible:** separa el conducto de los vapores y permite limpiar o sustituir la superficie expuesta. Se estudiaría una **inclinación inicial de 45°** para favorecer el escurrido, junto con materiales resistentes al ambiente térmico y tratamientos que faciliten la limpieza; ni la inclinación ni un recubrimiento garantizan por sí solos que no se acumule grasa.

4. **Iluminación y calibración:** una iluminación protegida y una referencia geométrica estable ayudarían a mantener imágenes comparables.



13. Estado del proyecto y siguiente paso

El sistema ya conecta segmentación de fondo, separación de piezas, clasificación de cortes de pollo, detección de rebozado, análisis geométrico y un motor de propuestas de cocinado. Los módulos cuentan con evaluaciones propias y el software tiene pruebas automatizadas.

El siguiente paso es una **prueba de concepto con un fabricante**: escoger un aparato y una cámara, evaluar imágenes tomadas en condiciones reales, ampliar y validar los alimentos prioritarios y calibrar los programas de cocción con ensayos físicos. El objetivo de la colaboración sería comprobar si esta tecnología puede convertirse en una función fiable, cómoda y diferenciadora para una futura airfryer.

El proyecto continúa en desarrollo activo, incorporando nuevas funcionalidades y mejoras constantes. El principal objetivo es ampliar progresivamente el reconocimiento de alimentos y perfeccionar los programas de cocinado, avanzando hacia un sistema de cocinado automático universal, fiable y adaptable a cualquier tipo de alimento.

Base documental y criterios de ingeniería

Para valorar el **concepto físico de cámara**, también se han tenido en cuenta principios ópticos de Edmund Optics sobre espejos de primera superficie y criterios generales de protección de ventanas y refrigeración empleados en sistemas de visión para altas temperaturas. Para la validación alimentaria, las recomendaciones de la FDA recuerdan que la apariencia no sustituye la medición de la temperatura interna segura.